

بررسی: کاربرد یادگیری تقویتی/یادگیری تقویتی عمیق در تخلیه بار وظایف وسایل نقلیه با استفاده از رایانش ابری لبه ای و

ابری کوچک وسایل نقلیه.

طاها بیک لریان

دانشگاه علم و صنعت

مقدمه

در سال های اخیر شاهد رشد چشمگیر وسایل نقلیه هوشمند بودیم. امروزه وسایل نقلیه حاوی تعداد زیادی از سنسور های تعبیه شده و دستگاه ای ذخیره سازی و پردازشی و تعداد زیادی ماژول های ارتباطی بی سیم هستند تا یک تجربه بهینه و مطمئن و راحت بسازند. این سرویس های وسایل نقلیه بطور پیوسته در حال پیشرفت و گسترش هستند که باعث شده اند که پردازش های سنگین داده داشته باشند و حساس به تاخیر باشند. منابعی که وسایل نقلیه در خود برای تخصیص دادن به پردازش داده دارند بسیار محدود هستند و توانایی پردازش حجم زیادی از داده هایی که حساس به زمان نیز هستند را ندارند. برای همین منظور نیاز به وجود تخلیه بار وظایف این وسایل نقلیه بین سطوح دیگری از پردازنده های داده است مانند فضای های ابری متمرکز یا فضا های ابری لبه یا ابر های کوچک وسایل نقلیه. این تخلیه بار وظایف در پردازش داده ها بین منابع مختلف باعث بهبود عملکرد اپ و کیفیت خدمات میشود. برای پی بردن به اهمیت موضوع میتوانیم به خودرو های خودران و سیستم های حمل و نقل هوشمند اشاره کرد که در این ها اپ ها و سرویس هایی وجود دارد که پردازش های بسیار سنگینی دارند و نمیتوانند در خود و با اتکا به منابع پردازشی محدود خود جوابگو این پردازش ها باشند. این اپ ها و سرویس ها در این وسایل نیاز به پاسخ های بلادرنگ (Real-time Response) و به دلیل مشکلات شبکه ای مانند transmission delay، ارتباطات ناپایدار راهکار های مبتنی بر ابر هم غیر قابل اجرا هستند. البته که سرور های پردازش ابری لبه ای (EC Computing) یا MEC که در زیرساخت های کنار جاده ای یا base station ها هستند میتوانند معماری های خوبی برای حل این مشکلات باشند. با رشد هوش مصنوعی و استفاده از آن در سیستم های بیسیم میتواند کار های مبتنی بر شبکه را بهبود ببخشد. برای مثال هوش مصنوعی سیستم های هوشمند حمل و نقل را بهبود بخشیده برای مثال: پیش بینی جریان/ بهینه سازی جریان ترافیک/ پیش بینی سرعت/ تشخیص تصادف/ تشخیص رانندگی نامتعارف و چیز های دیگر. ظهور و رشد اپ ها و سرویس هایی که مبتنی بر الگوریتم های هوش مصنوعی هستند که حساس به تاخیر هم هستند معمولاً، باعث رشد کارایی شده اند. به طور دقیق تر اگر بخواهیم صحبت کنیم الگوریتم های یادگیری تقویتی و یادگیری ژرف میتوانند در محیط های پیچیده کمک بسیاری بکنند و بطور دقیق تر کمک خیلی زیادی در تخلیه بار وظایف وسیله نقلیه انجام میدهند. با توجه به پویا بودن فضای عملکرد وسیله نقلیه و تغییر مداوم پارامتر

ها وجود یک فرمول و روش ثابت برای بهبود عملکرد آن کافی نیست و باید فرمول و روشی پویا را در پیش بگیریم تا با تغییر پارامتر های عملکردی بتوان روشی مناسب آن ارائه داد تا بیشترین بهینه سازی ممکن را در وسایل نقلیه انجام دهیم.

مقدمات پارادایم های پردازی.

همانطور که در بالاتر گفته شد، به دلیل محدودیت های وسایل نقلیه و مناسب و کافی نبودن منابع وسایل نقلیه برای پردازش انبوهی از داده هایی که سرویس ها و اپ هایی که برای کارایی بهتر آن وسایل نقلیه به کار میروند کافی نیست. با توجه به این محدودیت ها مجبوریم روی بیاوریم به پارادایم های پردازی قوی تر مانند CC, EC, VC. حال هرکدام از این پارادایم ها را به خلاصه تعریف میکنیم:

- **ابر های متمرکز (Centralized Cloud (CC):** این مدل از ابر که به صورت گسترده توسط شرکت های بزرگ مهیا می شوند و مورد استفاده قرار میگیرند. این مدل ابری به صورت گسترده منابعی را در اختیار میگذارد که می تواند محل پردازش داده های سنگین باشد و منطقاً در ازای آن مصرف قدرت خیلی زیادی هم دارند. البته به دلیل متمرکز بودن این مدل ابر ها، معمولاً از کاربر خیلی دور هستند و همین باعث افزایش زمان پردازش و پاسخ میشود و همین باعث عملکرد بد سرویس ها و اپ های وسایل نقلیه میشوند که مبتنی بر پردازش سریع داده هایشان هستند و حساس به تاخیر هستند. و البته اگر مقدار خیلی از زیادی از داده هم به صورت همزمان به این مدل ابر ها فرستاده بشن باعث ایجاد بار زیاد ترافیکی در شبکه ای با پهنای باند محدود میشود. از طرفی با گسترش هوش مصنوعی و استفاده از کاربرد های آن در وسایل نقلیه و خانه ها و شهر های هوشمند باعث شده که نیاز زیادی به پردازش و حافظه پیدا کنیم و از طرفی منابع وسایل نقلیه هم بشدت برای انجام این حجم از پردازش بسیار ضعیف هستند، و برای داشتن یک مجموعه ای از منابع برای پردازش و ذخیره سازی این حجم از دیتا، وسایل نقلیه داده های خود را بوسیله شبکه به یک ابر می فرستاد تا پردازش آنجا صورت بگیرد. با توجه به توضیح هایی که از ابر های متمرکز در یک مکان صحبت کردیم فرستادن این داده ها و پردازش و گرفتن جواب ممکن از زمان زیادی طول بکشد و با توجه به اینکه خیلی از این اپ ها و سرویس ها نیازمند پاسخ و پردازش سریع داده هایشان هستند این مدل از ابر ها می توانند باعث ضعیف شدن عملکرد این سرویس ها و اپ ها شوند و باعث افت کیفیت خدمات شوند.

- ابر لبه (Edge Cloud(EC)):: کلمه "لبه" در "ابر لبه" معنی گنگی دارد و لبه شبکه یک مکان منحصر به فرد صرفاً نیست، میتواند سایت های BS/RSU باشند یا روتر های شبکه باشند یا وسایل نقلیه نزدیک باشند یا یک دیتا سنتر محلی باشند. زیرساخت های EC میتوانند ضعف هایی که ابر های متمرکز داشتند را جبران کنند، مانند زمان پردازش و افزایش حجم ترافیکی در شبکه و ... EC ها نقش بسزایی در تضمین زمان تاخیر در پردازش و توان عملکردی با کم کردن فاصله بین محل تولید داده و محل پردازش آن دارند. برای گرفتن شهودی از زیرساخت های EC میتوان گفت که تقریباً هر منبع محاسباتی و پردازشی نزدیک وسایل نقلیه (محل تولید داده) با نظر به اینکه چه پردازش و کاری روی داده باید انجام شود، میتواند یک زیرساختی برای پردازش لبه ای باشند. برای مثال واحد های کنار جاده ای(RSU) می توانند به عنوان سرور های لبه عمل کنند ، که میتوانند به صورت بهینه داده را بگیرند و پردازش کنند و ذخیره کنند. خود وسایل نقلیه هم همانطور در قبل به آن اشاره کردیم منابع محدودی برای پردازش و ذخیره داده دارد و میتواند با انتقال وظایف و پردازش های داده به یکی از این سرور های لبه کار پردازش داده خود را انجام دهد و در مقایسه با ابر های متمرکز، ابر های لبه خیلی می توانند زمان پاسخ پردازش داده را کاهش دهند. البته در مقایسه با زیرساخت های متمرکز ابری، سرورها و زیرساخت های ابری لبه ای قدرت پردازش محدودی دارند. هوش مصنوعی همچنین به زیر ساخت های لبه ای هم وارد شده و عملکرد آن ها را مانند پردازش سریع کار ها مانند استنتاج، تطبیق الگو ها، تصمیم گیری و چیز های دیگر را بهبود بخشیده. ما ابر های لبه را به سه گروه تقسیم میکنیم: سرور های MEC(Multi-Access Edge Computing)، وسایل نقلیه نزدیک و MEC ترکیبی.

سرور های MEC:

این سرور ها به نوعی ابر های مرکزی سازی شده هستند، که نزدیک تر به محل تولید داده شده اند. این زیرساخت ها معمولا در base station های نسل 4 و 5 اینترنت هستند. در شبکه VEC استفاده از سرور های لبه متداول ترین روش برای تخلیه بار پردازشی است. که به معنای نصب دستگاه های RSU در مسیر جاده های شهر ها برای بودن به عنوان ابر لبه است. که انتقال داده از وسیله نقلیه به این زیرساخت ها از نوع (V2I (Vehicle to Infrastructure). محدوده ای که RSU ها می توانند به آن سرویس دهند محدود است و از آنجایی که وسایل نقلیه در حرکت هستند مشکل رخ میدهد که در اینجا سیستم های MEC باید تشخیص دهند و داده ها را به یک RSU دیگری انتقال دهند که وسیله نقلیه به سمت آن میرود.

وسایل نقلیه نزدیک:

علاوه بر تخلیه بار پردازشی به سرور های RSU یا BS، وسایل نقلیه می توانند بار پردازشی را روی وسایل نقلیه دیگر که در نزدیکی اش است تخلیه کند و این انتقال داده بین دو وسیله نقلیه به سبک (V2V (Vehicle to Vehicle صورت می گیرد. از آنجایی که شاید منابع وسایل نقلیه برای انجام پردازش هایی ضعیف هستند اما اگر این به معنای استفاده و مورد استفاده قرار دادن منابعی باشد که از آنها استفاده ای نمی شود میتواند باعث افزایش QoS استفاده کنندگان آن وسایل نقلیه شود.

ترکیبی MEC:

در این روش وسایل نقلیه میتوانند همزمان از دو روش بالا استفاده کنند و یک پردازش موازی انجام دهد. و برای مثال وقتی وسیله نقلیه ای از محدوده خدمات دهی یک RSU خارج میشود، وسیله نقلیه می تواند بار پردازش را روی وسیله نقلیه های اطراف بیاندازد و اگر هیچ وسیله نقلیه ای در کنارش نبود مستقیما با BS ارتباط برقرار میکند.

● ابر های خودرویی Vehicle Cloudlet:

از اونجایی که منابع محاسباتی وسایل نقلیه در حال گسترش هستند برای هوشمند سازی و وسایل نقلیه متصل به هم، میتوانیم از منابع آنها برای انجام پردازش های وسایل نقلیه دیگر استفاده کرد . VC متشکل از انبوهی از وسایل نقلیه ای است که منابع آنها مورد استفاده نیستند که شامل منابع پردازشی، ذخیره سازی و ارتباطی هستند. از کنار هم قرار گرفتن منابع این وسایل نقلیه می توان یک شبکه پردازش ابری درست کرد، که این ابری که بوسیله شبکه شدن وسایل نقلیه ای ایجاد شده اند خیلی شباهت به زیرساخت های ابری سنتی است اما با این تفاوت که از کنار هم قرار گرفتن منابع یکسری وسیله نقلیه درست شده اند. وسایل نقلیه می توانند در حال حرکت یا ثابت باشند. که یکی از چالش هایی که برای ماشین های پارک شده داریم که یک شبکه با هم ایجاد کردن، دانستن مدت زمانی است که ماشین در پارک باقی میماند تا بتوان یک تخصیص منابع مناسبی را با توجه به آن به یک وظیفه پردازشی داد.

مروری بر الگوریتم های یادگیری تقویتی و یادگیری تقویتی ژرف در تخلیه بار پردازشی وسایل نقلیه

با توجه به مسائل و موضوعاتی که برای انجام task offloading در بالا به آن اشاره شد، میتوان گفت که ما با مسائلی پویا و غیر ثابت رو به رویم که در هر زمان باید با توجه به شرایط پیش آمده و وضعیت موجود بهینه ترین تصمیم ممکن را بگیریم. حال با توجه به این فضای احتمالاتی که باید در تصمیم گیری ها در نظر گرفته شود میتوانیم از الگوریتم ها و مدل های مبتنی بر یادگیری تقویتی/تقویتی ژرف استفاده کرد تا بتوان بهینه سازی تصمیمات را در فضای احتمالاتی انجام داد.

• یادگیری تقویتی Reinforcement Learning:

معمولا برای توضیح RL از MDP استفاده میکنند که یک روند از کنترل احتمالاتی موقعیت و عمل در یک زمان گسسته است. اگر به طور خلاصه بخوایم بگیم فضایی که داریم روی آن کار میکنیم یکسری وضعیت یا state دارد که میتوان با کمک یک سری کنش ها یا همون action ها از state ای به state دیگری رفت، در پی این حرکت بین state ها یک سری تعاریفی از اینکه چه کنشی بهتره یا در چه state ای به مقصد نهاییمون نزدیک تریم وجود دارد که به آن ها مقادیری اختصاص میدهیم به عنوان تشویق/پاداش یا اگر کنش یا موقعیت خوب یا بهتری نباشد مقداری به آن عمل اختصاص می دهیم که به عنوان مجازات و بد بودن آن عمل تلقی میشود. برای انتخاب هر کنشی به صورت حریصانه آن کنش ممکن را انتخاب میکنیم که مارو به موقعیتی یا state ای می برد که ارزش یا value بیشتری دارد، خود ارزش هر state هم به صورت DP یا برنامه نویسی پویا بدست میاید که به روش Bellman معروف است. حال باید یک خط مشی بهینه بر اساس کنش ها و وضعیت هامون و ارزش هر کدام پیدا کنیم که مارو در کمترین زمان و بیشترین ارزش به مقصد نهایی برساند. برای این کار از value iteration استفاده میکنیم، این روش اما در محیط هایی که موقعیت ها و state های پیچیده تری دارند مثل محیط بررسی وسایل نقلیه. روش دیگری که برای یادگیری تقویتی استفاده میکنند Q-Learning است که یک الگوریتم model-free است به این معنا که تابع احتمال کنش ها و عمل ها را نداریم و agent باید به صورت مستقیم با محیط تعامل کنه و بعد از بدست آوردن تعداد زیادی خط سیر می تواند در نهایت مقدار تابع احتمال و تابع پاداش را

تخمین بزند. یکی از مشکلات Q-Learning این است که برای فضاهای خیلی بزرگ یا پیوسته ناکارآمد است به دلیل اینکه مجبور است Q-Table خیلی بزرگی داشته باشد.

الگوریتم Q-Learning برای فضا های کوچک و static مناسب است اما برای فضاهایی که خیلی بزرگ هستند و حالتی تعاملی دارند از آن جایی که مجبور به نگهداری و به روز رسانی Q-Table ای بسیار بزرگ هستیم به صرفه نخواهد بود و باید از روش های یادگیری ژرف و شبکه های عصبی در مدل های تقویتیمون استفاده کنیم. کاری که میکنیم این است که برای فضا های پیوسته Q-Table را به وسیله شبکه های عصبی تخمین میزنیم. میتوان از الگوریتم DQN استفاده کرد که مشکل آن Overestimation است که میتواند بعضی اوقات مقدار Q را بیش از اندازه حساب کند که میتواند باعث یک خط مشی غیر بهینه شود، برای حل این مشکل میتوان از Double DQN استفاده کرد که از دو تا شبکه عصبی برای انتخاب و ارزش گذاری عمل یا کنش استفاده میکند که باعث یک همگرایی پایدار تری میشود. میتوان از روش های مبتنی بر خط مشی (policy based) استفاده کرد مانند Actor-critic یا DDPG. و اضافه بر این ها می توان از Multi-Agent RL ها هم استفاده کرد که به نوعی چند Agent داریم که همگی با هم یاد میگیرند و در نهایت اطلاعات خود را به اشتراک میگذارند و بهترین تصمیم را میگیرند. ایراد این روش هم در این است که می توان منجر به افزایش ابعاد مساله شود از آنجایی که ترکیب تابع های کنش و محیط به صورت نمایی با افزایش تعداد Agent ها افزایش میابد.

TABLE III: Comparison of RL/DRL algorithms

Algorithms	Variants	Main Characteristics	Advantages	Disadvantages
VI	Policy Iteration(PI)	Use Dynamic programming method	Faster iteration efficiency	It relies on transfer matrix and is inefficient
Q-Learning	SARSA, Dyna-Q	Use Q table store all the Q value of action	Use TD sample and flexible and efficient sampling	It's inefficient in the continuous state
DQN	Dueling DQN	Use NN instead of Q table	Fast convergence and easy to implement	Over estimation for Q values
DDQN	/	The evaluation and selection of actions are implemented by dual networks	Convergence process is stable and fast	Deterministic strategies do not satisfy all cases
REINFORCE	PPO	Stochastic Policy	learning optimal strategy directly	With a high variance and low sample utilization
AC	A2C, A3C	Both policy update and value update are included	Higher update efficiency can handle continuous action environments	It is not easy to convergence
DDPG	MADDPG	Process continuous actions with deterministic strategies	Easy convergence and stability	Deterministic strategies cannot explore the action state space well
VDN	QMix	The total Q value is the sum of all agent Q value	Speed up the task learning	The total Q value fitting ability for complex environment is limited
QMix	/	The total Q value is obtained by mixing the Q values of all agents	Using mixing network has better performance for total Q	Usage scenarios are limited

روش های مبتنی بر RL/DL برای تخلیه بار وظایفی وسایل نقلیه با استفاده از شبکه زیرساخت های لبه (Edge)

قبل تر اشاره کردیم که وسایل نقلیه برای انجام یک سری وظایف محاسباتی نیاز به منابعی بزرگتر و قوی تر دارند که نیاز و با اینکه با پیشرفت خودرو های هوشمند منابع این وسایل نقلیه بهتر و قوی تر شده اند، اما همچنان برخی از وظایف و پردازش ها آنقدر سنگین هستند که توانایی انجام آن ها لااقل در زمان کم به وسیله منابع خود وسیله نقلیه انجام گیرد و لازم است که این وظایف و پردازش ها در جایی خارج از وسیله نقلیه و با امکانات و منابع محاسباتی بهتری انجام شوند که علاوه بر تلاش برای سریع تر کردن پاسخ دهی به وسیله نقلیه، کیفیت سرویس بهتری هم به کاربر ارائه دهیم. ما انجام کارهای محاسباتی و پردازشی داده ها را به چند بخش تقسیم میکنیم: آنهایی که به صورت محلی و بوسیله منابع خود وسیله نقلیه انجام می شوند (Local Execution) ، آنهایی که به یک زیرساخت قوی تر از لحاظ منابع اما نزدیک به منبع تولید داده منتقل می شوند (Complete Task Offloading) و آنهایی که مقداری از داده بصورت محلی در خود وسیله نقلیه پردازش می شود و مقداری از آن به یک زیرساخت قوی تر برای پردازش منتقل می شوند (Partial Task Offloading). حال با توجه به مدل های مختلف Edge node ها ما برای توضیح استفاده از RL و DRL در این زیرساخت ها آن ها را به سه دسته تقسیم میکنیم: طرح هایی که از سرور MEC استفاده میکنند، و یا از هر دو MEC و وسایل نقلیه استفاده کنیم، و در همین منوال کدام آنها HMEC ایست.

راهکار های RL و DRL برای استفاده از سرور های MEC:

سرور های MEC یکی از قسمت های مهم معماری شبکه های 5G است، که میتواند با پیاده سازی و گسترش منابع پردازشی و محاسباتی در نزدیکی وسایل نقلیه قابلیت های task offloading و traffic offloading را برای task های سنگین محیا کند. سرور های MEC از منابع معمول مورد انتخاب وسایل نقلیه برای task offloading است به دلیل نزدیکی و در دسترس بودن این سرورها. در این میان اینکه چه زمانی و روی کدام سرور و چه مقداری از دیتا را offload کند، وسایل نقلیه باید تصمیم بگیرند و روشی بهینه را انتخاب کنند. برای اینکه بتوانیم به صورت بهینه این کار ها را انجام دهیم، از مدل های یادگیری تقویتی و یادگیری ژرف استفاده میکنیم و در قسمت های بعدی دو رویکرد و مسائل و

راه حل هایی که در هر کدام ارائه شده اند را شرح می‌دهیم. از مشکلاتی که سعی در حل آن ها داریم تحرک زیاد وسایل نقلیه و شعاع محدودی که RSU ها میتوانند پوشش دهند که این دو متغیر بسیار چالش برانگیز هستند و رویکرد کلی همواره در بهینه سازی در بین وسایل نقلیه و زیرساخت های پردازشی است که باید به نوعی با استفاده از ابزار هایی که داریم با چالش هایی که روبرو هستیم این بهینه سازی ها را انجام دهیم. دو رویکردی که با آن مواجه هستیم:

● روش های Value-Based

● روش های Policy-Based

در هر کدام از دو روش بالا برای مدل ها و ایجنت های RL و DRL روش های متعددی و هر کدام با تمرکز بر حل یکی از چالش ها ارائه شده اند. یکی از روش هایی که ارائه شده به صورت بهینه سازی دوگانه ذخیره سازی داده و اختصاص محاسباتی در شبکه های ناهمگن وسایل نقلیه، با در نظر گرفتن نوسانات منابع و محدودیت های ظرفیت ذخیره سازی است و الگوریتم و مدلی که برای آن ارائه شده یک چارچوب مقیاس زمانی دوگانه است که از PSO برای مقیاس های زمانی بزرگتر و از DRL برای مقیاس های زمانی کوچکتر استفاده میکند که این باعث شده جواب ها و نتایج بهتری نسبت به حالت های تصادفی و حتی تکنیک های اختصاص دهی گرفته شود که به صورت Value-Based ارائه شدند که یکی از راهکارها برای حل مشکلات task offloading در پارادایم MEC است که به صورت Value-Based هستند. در این بین مقالات زیادی به اختصار توضیح داده شده اند که هر کدام تمرکز بر حل یکی از مشکل را دارند. که در جدول زیر به صورت خلاصه و دسته بندی شده آورده شده اند. در کل بر اساس بررسی های مقاله های این بخش عمدتاً بر کاهش تاخیر سرویس ها و هزینه های مصرف ارتباطی و سیستمی به عنوان هدف بهینه سازی خود متمرکز بودند. و این یک الزام برای برنامه های real-time با نیاز محاسباتی بالا و حساس به تاخیر است. با این حال در برخی از مقالات نویسندگان به QoS برای ارائه تجربه بهتر به کاربران توجه کرده اند. علاوه بر این بیشتر این طرح ها از offloading binary استفاده کرده اند که به این معنا که هیچ حالت هیبریدی وجود ندارد و از DSRC که یک فناوری کارآمد ارتباطی بیسیم با برد کوتاه است، استفاده کرده اند.

TABLE IV: Summary of RL/DRL Based Vehicular Task Offloading Papers Utilizing MEC Servers

Cate.	Ref.	Year	Offloading	RAT	Algorithm	RL/DRL Elements			Optimization Objective
						State	Action	Reward	
Value Based	[95]	2019	Binary	DSRC	DQN	The state of the available RSU/MEC server.	which RSU is assigned to the vehicle.	Cost of communication, storage and computation.	Minimize the system cost.
	[96]	2019	Binary	DSRC	DDQN	The communication channel gain and available computing capabilities.	The connection relationship among vehicles, RSUs and BS.	The lease cost of the spectrum bandwidth and the computing resource.	Maximize the comprehensive QoE of vehicles.
	[97]	2020	Binary	Cellular	DDQN	The interference degree of all users.	The select cellular channels for data transmission.	The long-term reward.	Minimize the offloading cost while satisfying the latency.
	[98]	2020	Binary	DSRC	Q-Learning	A table for each MEC that the estimated pending delay.	The available MEC servers to assigning the newly submitted task.	Task completion time.	Minimize task completion time.
	[99]	2020	Binary	DSRC	Q-Learning	/	/	/	Minimizing communication delay.
	[100]	2020	Partial	Cellular	Q-Learning	The assigned proportion of different offloading and the reserved bandwidth.	A traffic assignment of different offloading technologies.	The gain of selecting offloading technology.	Minimize the communication/computing budgets and the offloading failure probabilities.
	[101]	2020	Binary	DSRC	DQN	The computational task profile in each vehicle.	A vector about binary computational offloading.	The weighted sum of execute delay and energy consumption.	Minimize the sum cost of entire system.
	[102]	2021	Binary	DSRC	MA-DQN	The number of active vehicles, the set of uplink and offloading actions.	A vector about resource allocation decisions.	A negative function of the computation load balancing.	Maximize long-term network wide computation load balancing.
	[103]	2021	Binary	DSRC	Duling DQN	1.System resource allocation rate. 2.Channel allocation rate. 3.Task offloading completion degree.	A vector about offload decision for each vehicle.	The long-term cumulative discount reward value.	Minimize system energy consumption.
Policy Based	[104]	2020	Partial	DSRC	DDPG	The status of each vehicle and available resources of each MEC server.	The computational and caching resource, and bandwidth that MEC server allocates to vehicle.	Profit function include revenues, computation costs and the caching costs.	Maximize the benefit for the mobile network operator.
	[105]	2020	Partial	DSRC	DDPG	The buffer queue state in each equipment and the instantaneous channel state.	The transmitting and allocated power and proportion of bandwidth.	A cost function about energy consumption and buffer delay.	Minimize the total cost.
	[106]	2020	Binary	DSRC	PPO	1.local processing unit (LPU) 2.Data transmission unit (DTU). 3.MEC server state.	The task allocation of local execution (LE), remote execution (RE), and holding-on (HO)	The time and energy consumption of all the tasks.	Minimize the long-term cost in terms of a trade-off between task latency and energy consumption.
	[107]	2020	Partial	DSRC	DDPG	The vehicles real-time location and mission information.	A vehicle selection vector.	A functions about tasks information and actions.	Minimize the execution delay of the entire system.
	[108]	2020	Partial	DSRC	DDPG	1.The computing data amount in zones. 2.The average vehicle speed. 3.The delay for edge servers.	The index of receiver RSU, helper RSU, and deliver RSU.	The real-value cost.	Minimize the computing time.
	[109]	2020	Binary	DSRC	DDPG	The vehicle location and task information.	A vector about resource allocation decisions according to the policy.	A reward function about delay requirement and real delay.	Maximize the number of offloaded tasks with satisfied QoS.
	[110]	2021	Binary	DSRC	MADDPG	1. Vehicle and UAV's location . 2. Resource state of MeNB and UAV.	The resource allocation about UAV and MeNB.	A reward function about MeNB agent and UAV.	Maximize the number of offloaded tasks.

راهکار های RL و DRL برای استفاده از وسایل نقلیه نزدیک برای task offloading:

از آنجایی که منابع محاسباتی ای که در وسایل نقلیه هستند به طور کامل استفاده نمی شوند و قسمتی از آنها idle هستند، به همین دلیل می توان از آن ها برای offload کردن task ها بر روی آنها استفاده کرد و از منابع آزاد وسایل نقلیه دیگر برای پردازش ها و محاسبات استفاده کرد. و از طرفی هم به دلیل پوشش محدود RSU ها و در حرکت بودن وسایل نقلیه، وظایف باید بین RSU ها منتقل شود که همین باعث مصرف انرژی بالایی می شود. همچنین در مناطقی که فاقد پوشش RSU ها هستند میتوان از تخلیه بار محاسباتی بر روی منابع خودرو های نزدیک دیگر استفاده کرد تا بهره برداری منابع بهبود یابد. البته مشکلی که هست در حرکت بودن وسایل نقلیه و زیرساخت پردازشی آن است که زمان اتصال نسبت به زمانی که زیرساخت ثابتی وجود دارد کمتر است اما میتوان برای دو خودرویی که در یک مسیر با سرعتی تقریباً یکسان حرکت می کنند این مشکل را کمرنگ تر در نظر گرفت و در این شرایط می توانند زمان اتصال بیشتری داشته باشند و به

صورت توزیع شده وظایف پردازشی را به وسایل نقلیه دیگر که منابع آماده و idle دارند ارجاع دهد و به صورت مقرون به صرفه مدیریت کند. وسایل نقلیه می توانند وظایف را به صورت محلی محاسبه کنند یا آن ها را با حالت ارتباطی V2V به وسایل نقلیه مجاور offload کند تا در مصرف انرژی صرفه جویی کرده و پردازش را تسریع بخشد. برای این قسمت هم راهکارهایی بر مبنای RL و DRL و در دو رویکرد value-based و policy-based در مقالاتی مورد بررسی و به اختصار توضیح داده شده اند که مشکلاتی را که برای استفاده از این پارادایم محاسباتی وجود دارند را به صورت بهینه سازی هایی درست کنند. یکی از مقالات به حداقل رساندن تاخیر وظیفه و مصرف انرژی برای وظایفی با توپولوژی خطی منطقی و ترتیبی پرداخته است. در این مقاله وسایل نقلیه به دو گروه وسایل نقلیه "وظیفه" (آنهایی که نیاز به محاسبات دارند) و وسایل نقلیه "خدماتی" (آن هایی که ارائه دهنده منابع محاسباتی هستند) تقسیم شده اند. در این مقاله یک DQN پیشنهاد شده است که از فناوری بازپخش تجربه (experience replay) بهره میبرد و به عنوان یک الگوریتم آفلاین در نظر گرفته می شود. برای استنتاج زمان ماندگاری بر اساس داده های تاریخی، به جای در نظر گرفتن مسافت و سرعت، از استنتاج بیزی استفاده میکند. و مقاله های دیگر از جنس بهینه سازی در این بخش به اختصار توضیح داده شده اند که سعی در حل مشکلات این پارادایم محاسباتی دارند. در جدول پایین می توانید مقالات و راه حل هایی که در این زمینه ارائه شده اند را به صورت دسته بندی شده ببینید:

TABLE V: Summary of RL/DRL Based Vehicular Task Offloading Papers Utilizing Nearby Vehicles

Cate.	Ref.	Year	Offloading	RAT	Algorithm	RL/DRL Elements			Optimization Objective
						State	Action	Reward	
Value Based	[113]	2020	Partial	Cellular	DQN	The computation task, the data size of task, and sojourn time.	An integer variable represents the chosen server.	A function about total cost.	Minimize the overall costs of delay and energy.
	[114]	2020	Partial	Cellular	DDQN	1. The signal noise ratio (SNR) of channel. 2. the remaining available time and computing resources.	The task allocation for each server and prices.	The mean utility of offloading tasks.	Maximize the cumulative reward of the task vehicle for offloading tasks.
	[115]	2020	Partial	Cellular	DQN	A vector about the total task computation in the queue of the vehicles.	The task offloading strategy for the task allocated to vehicles.	A function about compound task's execution time.	Minimize the time of task.

همانطور که در جدول بالا مشاهده میکنید در این دسته، از فناوری ارتباطات سلولی استفاده می شود که ارتباط V2V با بهره گیری از رویکرد LTE Direct امکان پذیر می سازد. در پیاده سازی های مسائل بالا از روش partial برای offloading استفاده شده اند که در آن وظایف به چندین زیر وظایف تقسیم می شوند و بخشی از آن ها داخل خود وسیله نقلیه پردازش می شوند و بخشی از آن ها به وسایل نقلیه مجاور برای انجام پردازش فرستاده می شوند. مقالات بسیار کمی در این بخش از راحل های RL/DRL استفاده کرده اند، زیرا استفاده از وسایل نقلیه مجاور به عنوان اهداف offloading

وظیفه، منابع استفاده نشده را به کار می‌گیرد و در عین حال بار روی سرور MEC را کاهش می‌دهد. بنابراین، به طور کلی، در حالی که وظایف می‌توانند به وسایل نقلیه مجاور آفلود شوند، می‌توانند به صورت موازی به سرور MEC نیز offload شوند، که این یک MEC هیبریدی است.

راهکار های RL و DRL برای استفاده در HMEC:

این بخش درباره راهکار استفاده همزمان از زیرساخت های MEC و وسایل نقلیه مجاور صحبت می کند که به این روش ترکیبی Hybrid MEC می گویند. HMEC یک پارادایم offloading مقرون به صرفه است که به طور کارآمد از منابع اضافی وسایل نقلیه بهره برداری می کند و قابلیت محاسباتی را بدون هزینه اضافی، افزایش می دهد. در HMEC وظایف می توانند به یک زیرساخت MEC منسوب شوند مانند RSU ها با پروتکلی به اسم V2I و یا می توانند با پروتکلی به اسم V2V به وسایل نقلیه در نزدیکی خود منسوب شود. که این اجازه می دهد که در مکان هایی که زیرساخت های MEC مانند RSU ها وجود ندارند، وسایل نقلیه بتوانند با تخلیه بار محاسباتی رو وسایل نقلیه مجاور خود و بهره گیری از آنها راندمان محاسباتی را افزایش دهد، و در مکان هایی که زیرساخت های MEC وجود دارند HMEC شرایطی ایجاد می کند وظایف انتخاب های زیادی برای تخلیه بار محاسباتی داشته باشند. مانند بخش ها و پارادایم های گذشته از RL و DRL برای بهینه سازی مسائلی که در این روش offloading با آن ها درگیر هستیم استفاده می کنیم که همچنان به دو زیر دسته value-based و policy-based تقسیم می شوند. برای مثال در یکی از مقالات درباره مدیریت منابع و offloading وظایف در محاسبات لبه ای چند سروره تمرکز دارد. مدل آن ها شامل شبکه های سلولی و LTE-V بود که امکان انتقال وظایف به base station از طریق پروتکل V2B یا به واحد های RSU از طریق V2V و V2R را فراهم می کرد. یک الگوریتم مبتنی بر DQN برای به حداکثر رساندن سودمندی سیستم offloading تحت محدودیت های تاخیر طراحی شد. برای خلاصه ای از روش های value-based، بیشتر طرح ها در این دسته بر کاهش تاخیر سرویس دهی، کمینه کردن هزینه های مصرفی سیستم و QoS تمرکز داشتند. بسیاری از آن ها از binary offloading استفاده کرده و عمدتاً حالت DSRC یا فناوری های ارتباطی سلولی را به کار گرفتند. DQN و DDQN رایج ترین الگوریتم های یادگیری تقویتی عمیق در این قسمت هستند. و برای متد های policy-based اغلب از فناوری C-V2X، شامل LTE-V2X و

NR-V2X، به دلیل قابلیت آن در پشتیبانی از برنامه های پیشرفته V2X با الزامات سخت گیرانه پهنای باند، تاخیر و قابلیت اطمینان، استفاده کردند. الگوریتم DDPG به دلیل پایداری آموزش خود، به ویژه هنگام کار با فضا های عمل پیوسته، اغلب انتخاب می شود. اهداف بهینه سازی شامل کمینه کردن مصرف انرژی و زمان اجرای وظیفه، همراه با اطمینان از QoS بود. در جدول زیر مسائل و روش های حل آن ها با جزئیات آن ها به صورت خلاصه آورده شده اند:

TABLE VI: Summary of RL/DRL Based Vehicular Task Offloading Papers Utilizing HMEC

Cate.	Ref.	Year	Offloading	RAT	Algorithm	RL/DRL Elements			Optimization Objective
						State	Action	Reward	
Value Based	[116]	2018	Binary	DSRC	DQN	1) The states of the available RSU/MEC servers. 2) The available vehicles. 3) the available caches	A vector about allocation for each server.	The cost of communication storage and computation.	Minimize the system cost.
	[117]	2019	Binary	Cellular	DQN	A vector about the total computation required for each MEC.	The sets of task offloading strategies and offloading targets.	The utility of the offloading system.	Maximize offloading utility under given delay constraints.
	[118]	2019	Binary	Cellular	DQN	1) The available vehicular edge server. 2) The fixed edge server.	Computation task offloading strategy for selecting local computing	The VEC network utility.	The long-term utility.
	[119]	2019	Binary	Cellular	DQN	1) The vehicle speed, position and computing capacity. 2) Cumulative reward value.	A vector include the amount of computation resources contributed.	The cost of system.	Maximize resource contribution and resource utilization.
	[120]	2020	Partial	Cellular	DQN	The caching and position state of vehicles and RSU.	The scheduling actions for vehicular and RSU.	A function about total cost.	Minimize the system-wide data processing cost.
	[121]	2020	Partial	DSRC	DQN	The total processing delay of all the computation tasks.	The set of vehicles' offloading and communications decisions.	A function about task execute time.	Minimize the processing delay of computation tasks.
	[122]	2020	Partial	Cellular	DDQN	The computing power that each MEC server.	The offloading decision and resource allocation.	The long-term cumulative discount reward value.	Minimize the user cost.
	[123]	2021	Binary	DSRC	Q-Learning	The locations, speed and moving direction of vehicles and CPU frequencies for edge node.	A index represent the offloading decision.	Is inversely proportional to the minimum execution delay for the current state.	Minimize the average processing delay.
Policy Based	[124]	2020	Binary	Cellular	DDPG	The vehicle number, computing node resources and maximum service delay.	Decisions include offloading, service migration and resource allocation.	A function is negatively related to the execution time.	Minimize task execution time.
	[125]	2020	Partial	Cellular	DDPG	The energy consumption via V2V and R2V mode.	The decision-making about the task-data chunk.	Value of QoE.	Minimize energy consumption.

راهکار های RL و DRL برای استفاده در task offloading وسایل نقلیه با استفاده از Cloudlet های وسیله های نقلیه:

برخلاف استفاده از نود های edge برای offload کردن task ها، وسایل نقلیه با منابع محاسباتی قدرتمند هم می توانند یک ابر تشکیل دهند که به vehicle cloudlet شناخته می شود. برای کمی کردن منابع پردازشی در VC ها، منابع پردازشی ای که توسط وسایل نقلیه ارائه می شوند با تعداد واحد های منابعشان اندازه گیری می شوند. این پارادایم می تواند در زمان

هایی که زیرساخت های MEC با پردازش task ها و داده ها اشباع شده اند مفید واقع شوند، و قدرت پردازش را بالا می برد و هزینه برقراری زیرساخت ها را هم کاهش می دهد. این منابع از یک استخر منبعی درست میشوند که بوسیله یک سیستم متمرکز vehicle cloudlet کنترل می شوند. محیط های VC بشدت پویا هستند و زمان های ماندگاری کم و غیر قابل پیش بینی ای دارند. که به این معناست که منابع می توانند به سرعت با خارج شدن وسائل نقلیه از cloudlet از دسترس خارج شوند که این لزومی بر وجود task migration یا مهاجرت وظایف توسط مدیریت منابع دیتاسنتر های VC صورت می گیرد. تخصیص منابع به صورت پویا و دینامیک در VC بسیار پر چالش هستند به دلیل اینکه منابع پس از مجازی سازی، به جای فرم فیزیکی، بر اساس زمان و میزان استفاده ارائه می شوند. برای حل چالش های این پارادایم نیز از ایده ها و الگو های قبل در مقالات مختلف استفاده شده اند. مشکلات این پارادایم در چند دسته تقسیم شده اند: مدیریت پویایی و عدم قطعیت در وسایل نقلیه، تخصیص و بهینه سازی منابع.

برای مثال برای موضوع عدم قطعیت در وسایل نقلیه و مدیریت پویایی مقاله ای با ارائه یک تکنیک تکثیر وظیفه، مشکل عدم تکمیل وظایف قبل از خروج خودرو از ناحیه پوششی رایانش ابری وسایل نقلیه را حل کردند. هدف آنها به حداقل رساندن احتمال نقض ضرب الاجل وظایف بود، با استفاده از الگوریتم value iteration و پیشنهاد یک سیستم تخصیص وظیفه متعادل BETA. آن ها توزیع پواسون را برای ورود خودرو ها و توزیع نمایی مستقل را برای زمان باقی مانده تا رسیدن خودرو به RSU فرض کردند.

اکثر راحل ها در دسته VC از الگوریتم های value-based استفاده می کنند، با DQN و مشتقات آن که به طور مکرر به کار می روند. تعداد کمتری از طرح ها از راحل های policy-based مانند A3C و PPO استفاده می کنند. به حداقل رساندن تاخیر زمانی (مانند اجرا، پاسخ دهی، پردازش) یک هدف بهینه سازی غالب در سناریو های VC است، به ویژه از آنجایی که هم وسایل نقلیه خدماتی و هم مأموریتی سیار هستند و اغلب قدرت محاسباتی محدودی دارند، که وظایف را مقید به زمان می کند. سایر اهداف شامل به حداقل رساندن پاداش بلندمدت، بهبود بهره برداری از منابع و به حداقل رساندن مصرف انرژی است. Task migration یک جنبه حیاتی است که اغلب به دلیل مصرف منابع، کل هزینه را افزایش می دهد، که نیاز به الگوریتم های انتخاب چندمسیره را برجسته می کند. در جدول زیر نیز مدل ها و مسائل ارائه شد در مورد حل این مشکلات و بهینه سازی های سیستم های VC ارائه شده اند را می توانید مشاهده کنید:

TABLE VII: Summary of RL/DRL Based Vehicular Task Offloading Papers Utilizing Vehicle Cloudlet

Cate.	Ref.	Year	Offloading	RAT	Algorithm	RL/DRL Elements			Optimization Objective
						State	Action	Reward	
Value Based	[129] 2018	2018	Binary	DSRC	VI	1.The number of elapsed time. 2.The number of current replicas of task which are being processed.	A vector about decision for server.	The number of finished tasks in a time slot.	Minimize the deadline violation probability.
	[130]	2018	Binary	Cellular	DQN	The task and the current locations of all the vehicles.	A vector that decide which the next task should be migrated.	The overall response time	Minimize the overall response time.
	[131]	2018	Binary	DSRC	VI	The number of the fog servers at the current state and fog servers allocated to the tasks in the queueing.	A number represent the decision for task.	The difference between the revenue and system cost.	Maximize the long term expected reward.
	[132]	2018	Binary	DSRC	VI	Including service requests,number of vehicles of different types and event.	The number of RU allocated for arrival requests.	The difference of the revenue and expected cost.	Maximize the long-term reward.
	[133]	2019	Partial	DSRC	DDQN	1.The arrival rate of vehicles and tasks flows.2.The number of parked vehicles in range of RSU.	A number about offloading decision for task.	A function inversely proportional to energy consumption.	To minimize the overall energy consumption.
	[134]	2021	Partial	Cellular	Dyna-Q	1.The request event. 2. The number of virtual unit (Vus). 3.The number of important/ordinary service requests allocated to VU.	The model's response to and redistribution of received service requests.	The difference between system revenue and consumption.	Improve resource utilization and system QoS.
Policy Based	[135]	2019	Partial	Cellular	A3C	1.A tensor of the task.2.A tensor about all node.3.The moving speed of the vehicle.	A vector representing the execution position of a task.	The task execution delay.	Minimize the task execution delay.
	[136]	2019	Binary	DSRC	A3C	/	/	/	The user satisfaction for service latency.
	[137]	2020	Binary	DSRC	PPO	The vehicle movement and parking status.	A vector of the fraction of the computation load for service that is assigned to VF.	The service satisfaction obtained from a time slot.	Minimize the service latency.

خلاصه

در خواندن این بررسی از مقالات مختلف درباره استفاده از RL و DRL در task offloading وسایل نقلیه خواندیم و متوجه شدیم که پیدا کردن یک خط مشی بهینه برای offload کردن task ها در فضایی که بسیار ابعاد آن بزرگ است استفاده از روش های حریصانه و پایه ای بی فایده است و باید از روش های مبتنی بر RL و یادگیری عمیق مانند DQN, DDQN استفاده کرد. و اگر مدل از تخلیه جزئی task پشتیبانی می کند الگوریتم های policy-based مانند DDPG انتخاب بهتری برای فضاهایی با ابعاد بسیار بزرگ هستند. با در نظر گرفتن پیچیدگی بالای فضای MEC بهترین روش این است که مسئله را به دو زیر مسئله تبدیل کنیم: زمان بندی درخواست های task offloading و تخصیص منابع. الگوریتم های بر پایه RL تلاش میکنند که یک خط مشی و سیاستی را برای تخصیص منابع پیدا کنند که بهینه باشد. برای مسئله زمان بندی درخواست های offloading یک طرح تطبیق دو طرفه و تغییر جهت جریان می تواند استفاده شود. هدف های بهینه سازی مدل عمدتاً بهبود تاخیر زمان اجرا و بهینه کردن مصرف کلی سیستم است. از آنجایی که اکثر برنامه ها در محیط خودرو حساس به زمان هستند، بهینه سازی تاخیر های زمانی برای خدمات خودرو مهم است. انتقال و مهاجرت وظایف و task هایی که برخی از اوقات بین وسایل نقلیه صورت می گیرد می تواند هزینه های مصرفی را افزایش دهد به دلیل مصرف منابع. الگوریتم های مسیریابی زیادی باید اجرا شود که مسیری بهینه برای انتقال داده ها و وظایف بین وسایل نقلیه صورت بگیرد که هزینه مصرفی و مهاجرت task ها را کاهش دهد. در مجموع این مقاله بررسی یک شمایی کلی از task offloading های بر پایه RL و DRL در وسایل نقلیه در زمینه تکنولوژی در حال رشد شبکه های 6G ارائه کرد. در ابتدا یک توضیح مختصر از پارادایم های پردازشی موجود برای task ها و داده های وسایل با مزایا و معایبش ارائه شد. بعد از توضیح مختصری درباره یادگیری تقویتی و یادگیری ژرف و زمان استفاده این دو باهم و معایب و مزایا و حالت های مختلف هر کدام به اختصار بررسی شد. بعد از آن استفاده از این مدل های هوشمند را در پارادایم های محاسباتی که در اول توضیح داده شد دیدیم و مقاله هایی که مشکلی را درباره بهینه سازی و تقویت عملکرد پارادایم های محاسباتی مطرح کرده بودند و راه حل هایی مبتنی بر مدل های هوشمند و الگوریتم های value-based و policy-based مدل های RL و DRL ارائه کرده بودند را دیدیم.

پایان